主成分分析

Principal component analysis

主成分分析的基本思想

主成分的计算

主成分分析的应用

§1 基本思想

主成分分析的基本思想

主成分分析就是把原有的多个指标转化成少数几个代表性较好的综合指标，这少数几个指标能够反映原来指标**大部分**的信息（**85%以上**），并且各个指标之间保持独立，避免出现重叠信息。

主成分分析主要起着**降维**和**简化数据结构**的作用。

主成分分析是把各变量之间互相关联的复杂关系进行简化分析的方法。

在社会经济的研究中，为了全面系统的分析和研究问题，必须考虑许多经济指标，这些指标能从不同的侧面反映我们所研究的对象的特征，但在某种程度上存在信息的重叠，具有一定的相关性。

主成分分析试图在力保数据信息丢失最少的原则下，对这种多变量的数据进行最佳综合简化，也就是说，对高维变量空间进行降维处理。

很显然，识辨系统在一个低维空间要比在一个高维空间容易得多。

在力求数据信息丢失最少的原则下，对高维的变量空间降维，即研究指标体系的少数几个线性组合，并且这几个线性组合所构成的综合指标将尽可能多地保留原来指标变异方面的信息。这些综合指标就称为主成分。

要讨论的问题是：

(1) 基于相关系数矩阵做主成分分析?
(2) 选择几个主成分?
(3) 如何解释主成分所包含的实际意义?

§2 数学模型与几何解释

假设我们所讨论的实际问题中，有p个指标，我们把这p个指标看作p个随机变量，记为X_1，X_2，…，X_p。主成分分析就是要把这p个指标的问题，转变为讨论 m 个新的指标F_1，F_2，…，F_m(m<p）。按照保留主要信息量的原则充分反映原指标的信息，并且相互独立。

$$X=\begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}=\begin{pmatrix} X_1 & X_2 & \cdots & X_p \end{pmatrix}$$

其中 $X_i=\begin{pmatrix} X_{1i} \\ X_{2i} \\ \vdots \\ X_{ni} \end{pmatrix}$

这种由讨论多个指标降为少数几个综合指标的过程在数学上就叫做降维。主成分分析通常的做法是，寻求原指标的线性组合F_i。

$$F_1 = a_{11}X_1 + a_{21}X_2 + \cdots + a_{p1}X_p$$

$$F_2 = a_{12}X_1 + a_{22}X_2 + \cdots + a_{p2}X_p$$

$$\cdots\cdots$$

$$F_p = a_{1p}X_1 + a_{2p}X_2 + \cdots + a_{pp}X_p$$

满足如下的条件：

- **每个主成分的系数平方和为1。即**

$$a_{1i}^2 + a_{2i}^2 + \cdots + a_{pi}^2 = 1$$

- **主成分之间相互独立，即无重叠的信息。即**

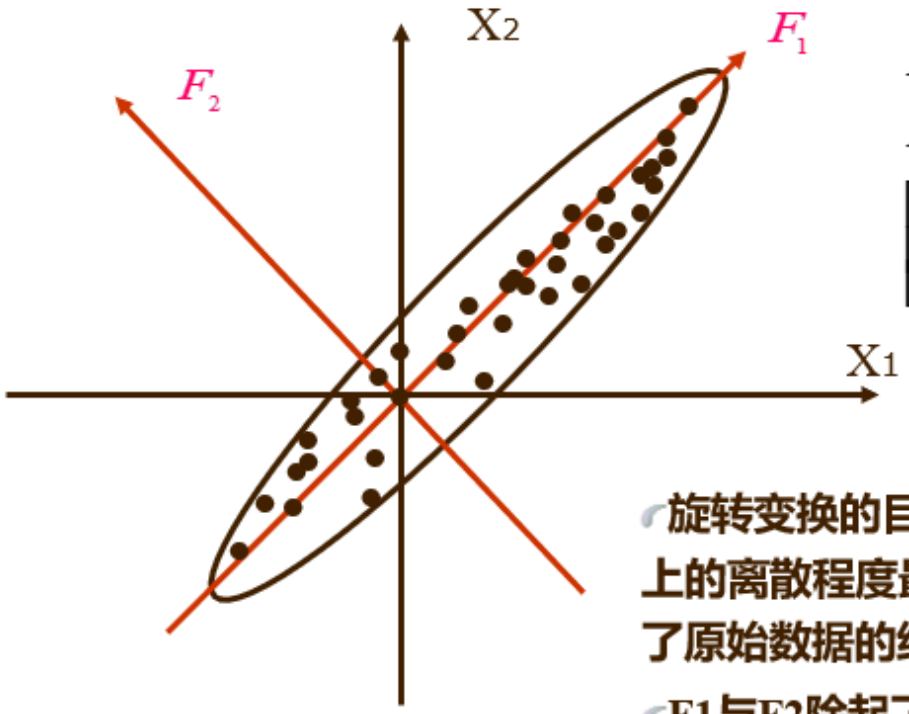
$$Cov(F_i, F_j) = 0,\ i \neq j,\ i, j = 1, 2, \cdots, p$$

- **主成分的方差依次递减，重要性依次递减，即**

$$Var(F_1) \geq Var(F_2) \geq \cdots \geq Var(F_p)$$

主成分分析的几何解释

旋转坐标轴



$$F_1 = x_1 \cos\theta + x_2 \sin\theta$$

$$F_2 = -x_1 \sin\theta + x_2 \cos\theta$$

$$\begin{bmatrix} F_1 \\ F_2 \end{bmatrix} = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

- 旋转变换的目的是为了使得n个样本点在F1轴方向上的离散程度最大，即F1的方差最大，变量F1代表了原始数据的绝大部分信息。
- F1与F2除起了浓缩作用外，还具有不相关性。
- F1称为第一主成分，F2称为第二主成分。

主成分的计算

先讨论二维情形

$$X=\begin{pmatrix} X_{11} & X_{12} \\ X_{21} & X_{22} \\ \vdots & \vdots \\ X_{n1} & X_{n2} \end{pmatrix} \hat{=} \begin{pmatrix} X_1 & X_2 \end{pmatrix}$$

求主成分F_1和F_2。

我们已经把主成分**F1**和**F2** 的坐标原点放在平均值$(\bar{x}_1, \bar{x}_2)$所在处，从而使得**F1**和**F2** 成为中心化的变量，即**F1**和**F2**的样本均值都为零。

因此$\mathbf{F_1}$可以表示为

$$F_1 = a_{11}(x_1 - \bar{x}_1) + a_{21}(x_2 - \bar{x}_2)$$

关键是，寻找合适的单位向量 (a_{11}, a_{21})，使$\mathbf{F_1}$的方差最大。

问题的答案是：**X**的协方差矩阵**S** 的最大特征根 λ_1 所对应的单位特征向量即为 (a_{11}, a_{21})。并且 λ_1 就是$\mathbf{F_1}$的方差。

同样，$\mathbf{F_2}$可以表示为 $F_2 = a_{12}(x_1 - \bar{x}_1) + a_{22}(x_2 - \bar{x}_2)$

寻找合适的单位向量 (a_{12}, a_{22})，使$\mathbf{F_2}$与$\mathbf{F_1}$独立，且使$\mathbf{F_2}$的方差（除$\mathbf{F_1}$之外）最大。

问题的答案是：**X**的协方差矩阵**S** 的第二大特征根 λ_2 所对应的单位特征向量即为 (a_{12}, a_{22})。并且 λ_2 就是$\mathbf{F_2}$的方差。

$$F_1 = a_{11}(x_1 - \bar{x}_1) + a_{21}(x_2 - \bar{x}_2)$$

$$F_2 = a_{12}(x_1 - \bar{x}_1) + a_{22}(x_2 - \bar{x}_2)$$

其中，a_{ij}称为因子载荷量

因子载荷量：主成分与变量间的相关系数，

其中，因子载荷量的大小和它前面的正负号直接反映了主成分与相应变量之间关系的密切程度和方向。从而可以说明各主成分的意义。

求解主成分的步骤：

1. 求样本均值 $\overline{X}=(\overline{x}_1,\overline{x}_2)$ 和样本协方差矩阵**S;**

2. 求**S**的特征根

求解特征方程$|S-\lambda I|=0$，其中**I**是单位矩阵，解得**2**个特征根 $\lambda_1,\lambda_2(\lambda_1\geq\lambda_2)$

3. 求特征根所对应的单位特征向量

4. 写出主成分的表达式

$$F_1=a_{11}(x_1-\overline{x}_1)+a_{21}(x_2-\overline{x}_2)$$

$$F_2=a_{12}(x_1-\overline{x}_1)+a_{22}(x_2-\overline{x}_2)$$

例1 下表是10位学生的身高 x_1 、胸围 x_2 、体重 x_3 的数据。

身高 x_1(cm)	胸围 x_2(cm)	体重 x_3(kg)
149.5	69.5	38.5
162.5	77.0	55.5
162.7	78.5	50.8
162.2	87.5	65.5
156.5	74.5	49.0
[illegible]	74.5	45.5
172.0	76.5	51.0
173.2	81.5	59.5
159.5	74.5	43.5
157.7	79.0	53.5

截图(Alt + A)

对此进行主成分分析。

1. 求样本均值和样本协方差矩 阵

$$\begin{pmatrix}\overline{x_1}\\ \overline{x_2}\\ \overline{x_3}\end{pmatrix}=\begin{pmatrix}161.2\\ 77.3\\ 51.2\end{pmatrix} \qquad S=\begin{pmatrix}46.67 & & \\ 17.12 & 21.11 & \\ 30.00 & 32.58 & 55.53\end{pmatrix}$$

2. 求解协方差矩阵的特征方程 $|S-\lambda I|=0$

$$\begin{vmatrix}46.67-\lambda & 17.12 & 30.00\\ 17.12 & 21.11-\lambda & 32.58\\ 30.00 & 32.58 & 55.53-\lambda\end{vmatrix}=0$$

3.解得三个特征值 和对应的单位特征向量:

$\lambda_1 = 98.15$ $\quad (a_{11}, a_{21}, a_{31}) = (0.56, 0.42, 0.71)$

$\lambda_2 = 23.60$ $\quad (a_{12}, a_{22}, a_{32}) = (0.81, -0.33, -0.48)$

$\lambda_3 = 1.56$ $\quad (a_{13}, a_{23}, a_{33}) = (0.03, 0.85, -0.53)$

4. 由此我们可以写出三个主成分的表达式：

$$F_1 = 0.56(x_1 - 161.2) + 0.42(x_2 - 77.3) + 0.71(x_3 - 51.2)$$

$$F_2 = 0.81(x_1 - 161.2) - 0.33(x_2 - 77.3) - 0.48(x_3 - 51.2)$$

$$F_3 = 0.03(x_1 - 161.2) + 0.85(x_2 - 77.3) - 0.53(x_3 - 51.2)$$

三个主成分的方差贡献率分别为：

$$\frac{\lambda_1}{\sum_{i=1}^{3}\lambda_i}=\frac{98.15}{98.15+23.60+1.56}=\frac{98.15}{123.31}=79.6\%$$

$$\frac{\lambda_2}{\sum_{i=1}^{3}\lambda_i}=\frac{23.60}{123.31}=19.1\%$$

$$\frac{\lambda_3}{\sum_{i=1}^{3}\lambda_i}=\frac{1.56}{123.31}=1.3\%$$

前两个主成分的累积方差贡献率为：

$$\frac{\lambda_1+\lambda_2}{\sum_{i=1}^{3}\lambda_i}=\frac{121.75}{123.31}=98.7\%$$

多指标 求解主成分的步骤：

在一般情况下，设有**n**个样品，每个样品观测**p**个指标，将原始数据排成如下矩阵：

$$\begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

1.求样本均值 $\overline{X}=(\overline{x_1},\overline{x_2},...,\overline{x_p})'$ 和样本协方差矩阵S;

2.求解特征方程 $|S-\lambda I|=0$, 其中I是单位矩阵

解得p个特征根 $\lambda_1,\lambda_2,...,\lambda_p \ (\lambda_1\geq\lambda_2\geq...\geq\lambda_p)$

3. 求 λ_k 所对应的单位特征向量 $\alpha_k \ (k=1,2,...,p)$

解得 $\alpha_k=(a_{1k},a_{2k},...,a_{pk})'$

4. 写出主成分的表达式

$$F_k=a_{1k}(x_1-\overline{x_1})+a_{2k}(x_2-\overline{x_2})+...+a_{pk}(x_p-\overline{x_p})$$

或$F_k=a_{1k}x_1+a_{2k}x_2+...+a_{pk}x_p$

主成分个数的选取原则

根据累积贡献率的大小取前面m 个(m<p)主成分

选取原则：

$$\frac{\sum_{i=1}^{m-1}\lambda_i}{\sum_{i=1}^{p}\lambda_i} < 80\sim 85\% \quad \text{且} \quad \frac{\sum_{i=1}^{m}\lambda_i}{\sum_{i=i}^{p}\lambda_i} \geq 80\sim 85\%$$

案例1—亚麻籽品种氨基酸测定及品质评价

2.3.1　主成分提取　以 12 个亚麻籽品种的 17 种氨基酸含量指标构成 17×12 的矩阵，利用 R 语言对其进行主成分分析，结果见表 4。由表 4 可知，前 3 个主成分对应特征值均＞1，累计方差贡献率达 86.695%，说明可以用前 3 个主成分代替 17 个氨基酸指标对 12 个亚麻籽品种进行品质综合评价。由表 5 可知，3 个主成分对应特征向量为：

表 4　12 个亚麻籽品种氨基酸主成分分析的特征值、贡献率和累计贡献率

Table 4　Eigenvalue, contribution and cumulative contribution of amino acid principal component analysis of 12 flaxseed varieties

主成分	特征值	贡献率/%	累计贡献率/%
PC1	10.291	60.536	60.536
PC2	2.550	15.002	75.538
PC3	1.897	11.157	86.695

表 5　12 个亚麻籽品种氨基酸主成分的特征向量与载荷矩阵

Table 5　Principal component eigenvectors and loading matrix of amino acid component of 12 flaxseed varieties

氨基酸	PC1		PC2		PC3	
	特征向量	载荷	特征向量	载荷	特征向量	载荷
Met	0.198	0.636	−0.082	−0.131	0.221	0.304
Lys	0.282	0.905	0.223	0.355	−0.031	−0.043
Val	0.252	0.809	−0.131	−0.210	0.256	0.353
Ile	0.288	0.925	0.149	0.238	−0.133	−0.184
Leu	0.179	0.575	−0.407	−0.650	0.147	0.203

Phe	0.132	0.422	0.308	0.492	0.327	0.450
Thr	0.213	0.682	−0.431	−0.689	0.021	0.029
Asp	0.250	0.803	−0.350	−0.560	0.109	0.150
Ser	0.269	0.864	−0.076	−0.121	−0.250	−0.344
Glu	0.283	0.909	0.224	0.358	−0.079	−0.109
Gly	0.277	0.887	−0.082	−0.131	−0.233	−0.321
Ala	0.296	0.950	0.137	0.219	−0.117	−0.160
Cys	−0.072	−0.231	0.297	0.474	0.592	0.815
Tyr	0.156	0.499	−0.227	−0.362	0.472	0.649
His	0.283	0.906	0.122	0.194	−0.097	−0.134
Arg	0.293	0.939	0.164	0.262	0.007	0.009
Pro	0.255	0.818	0.269	0.429	0.084	0.115

$$P_{C1}=0.198x_1+0.282x_2+0.252x_3+0.288x_4+0.179x_5+0.132x_6+0.213x_7+0.250x_8+0.269x_9+0.283x_{10}+0.277x_{11}+0.296x_{12}-0.072x_{13}+0.156x_{14}+0.283x_{15}+0.293x_{16}+0.255x_{17}, \quad (4)$$

$$P_{C2}=-0.082x_1+0.223x_2-0.131x_3+0.149x_4-0.407x_5+0.308x_6-0.431x_7-0.350x_8-0.076x_9+0.224x_{10}-0.082x_{11}+0.137x_{12}+0.297x_{13}-0.227x_{14}+0.122x_{15}+0.164x_{16}+0.269x_{17}, \quad (5)$$

$$P_{C3}=0.221x_1-0.031x_2+0.256x_3-0.133x_4+0.147x_5+0.327x_6+0.021x_7+0.109x_8-0.250x_9-0.079x_{10}-0.233x_{11}-0.117x_{12}+0.592x_{13}+0.472x_{14}-0.097x_{15}+0.007x_{16}+0.084x_{17}。 \quad (6)$$

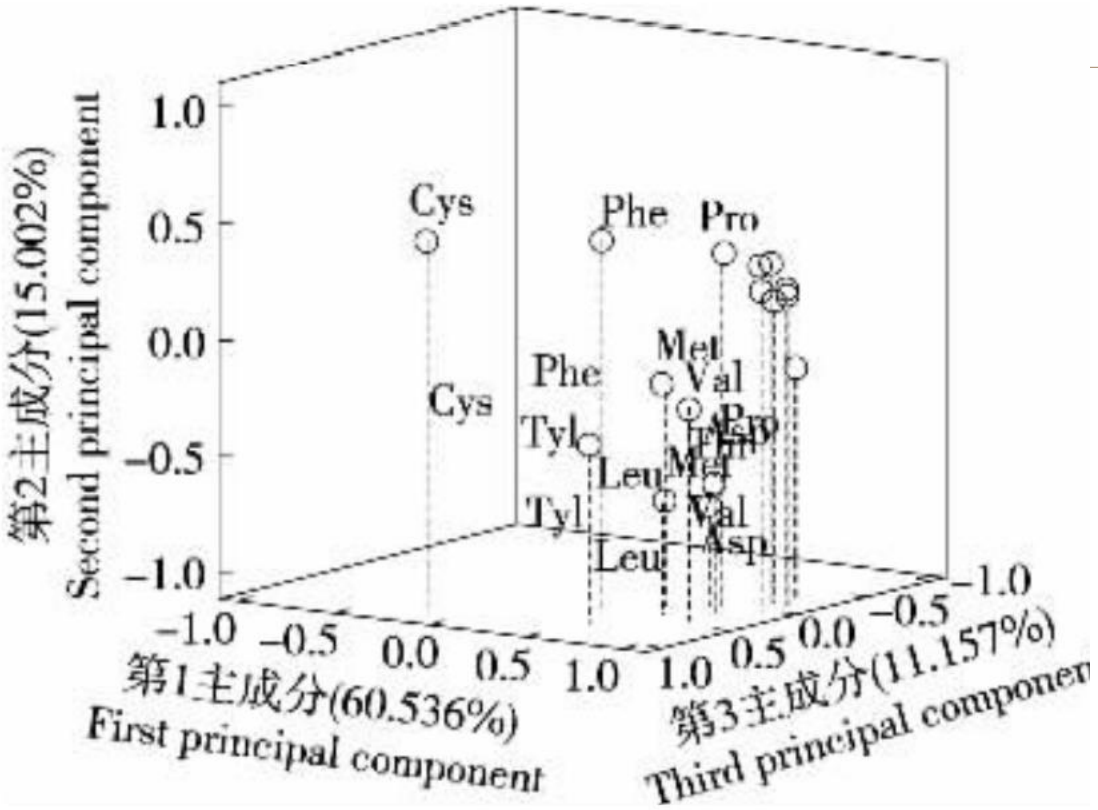

第2主成分(15.002%)
Second principal component
1.0
0.5
0.0
−0.5
−1.0
Cys
Cys
Phe
Pro
Phe
Met
Val
Tyl
Leu
Tyl
Leu
Val
Asp
−1.0 −0.5 0.0 0.5 1.0
第1主成分(60.536%)
First principal component
1.0 0.5 0.0 −0.5 −1.0
第3主成分(11.157%)
Third principal componer

图 1　主成分图

由图 1 可知，PC1 的方差贡献率为 60.536%，其中 Ala(x_{12})和 Arg(x_{16})的系数较大，分别为 0.296 和 0.293；PC2 的方差贡献率为 15.002%，其中 Thr(x_7)和 Leu(x_5)的系数较大，分别为 0.431 和 0.407；PC3 的方差贡献率为 11.157%，其中 Cys(x_{13})的系数最大，为 0.592。综上，Ala、Arg、Thr、Leu 和 Cys 可以作为 12 个亚麻籽品种基于氨基酸含量的综合评价指标。课题组前期研究发现，

案例2—红树莓籽油贮藏过程中综合品质的主成分分析

采用主成分分析法以红树莓籽油贮藏过程中过氧化值、棕榈酸、硬脂酸、油酸、亚油酸、亚麻酸、花生酸、SFA、MUFA、PUFA、UFA、β-谷甾醇、α-生育酚、DPPH·清除率、$ABTS^{+}$·清除率为指标进行主成分分析。结果见表 4、表 5。

表 4 红树莓籽油贮藏过程中综合品质指标主成分的特征值及方差贡献率

组分	初始特征值			提取平方和载入		
	合计	方差的%	累积%	合计	方差的%	累积%
1	9.830	65.535	65.535	9.830	65.535	65.535
2	1.631	10.872	76.407	1.631	10.872	76.407
3	1.439	9.593	86.000	1.439	9.593	86.000
4	1.095	7.301	93.301	1.095	7.301	93.301
5	0.570	3.799	97.101			
6	0.210	1.400	98.501			
7	0.140	0.936	99.437			
8	0.077	0.516	99.953			
9	0.007	0.047	100.000			

表 5 主成分载荷矩阵、特征向量和权重分析

Table 5 Principal component load matrix, feature vector and weight analysis

组分	第一主成分		第二主成分		第三主成分		第四主成分		综合指标	权重	排序
	载荷	特征向量	载荷	特征向量	载荷	特征向量	载荷	特征向量			
过氧化值	-0.757	-0.282	-0.216	-0.252	0.462	0.375	0.153	0.117	-0.180	0.0570	10
棕榈酸	0.660	0.246	-0.089	-0.104	-0.617	-0.501	0.171	0.131	0.119	0.0378	15
硬脂酸	-0.884	-0.329	0.217	0.253	0.260	0.211	0.283	0.217	-0.163	0.0517	12
油酸	0.880	0.328	0.219	0.255	-0.064	-0.052	-0.316	-0.242	0.236	0.0747	6
亚油酸	0.802	0.299	0.544	0.634	-0.017	-0.014	0.152	0.116	0.291	0.0924	3
亚麻酸	0.741	0.276	0.075	0.087	0.624	0.506	-0.002	-0.002	0.256	0.0812	4
花生酸	0.487	0.181	0.400	0.466	-0.249	-0.202	0.698	0.534	0.203	0.0643	9
SFA	-0.753	-0.280	0.338	0.394	0.152	0.123	0.205	0.157	-0.126	0.0400	13
MUFA	0.883	0.329	0.214	0.249	-0.075	-0.061	-0.309	-0.236	0.235	0.0746	7
PUFA	0.854	0.318	0.294	0.342	0.409	0.332	0.066	0.051	0.301	0.0956	1
UFA	0.917	0.341	0.285	0.332	0.268	0.217	-0.059	-0.045	0.297	0.0943	2
β-谷甾醇	0.926	0.345	-0.325	-0.379	0.055	0.045	0.054	0.041	0.206	0.0653	8
α-生育酚	0.962	0.358	-0.167	-0.195	0.021	0.017	0.123	0.094	0.238	0.0755	5
DPPH·	0.846	0.315	-0.480	-0.559	0.210	0.170	0.057	0.044	0.177	0.0561	11
ABTS+·	0.649	0.242	-0.572	-0.666	0.080	0.065	0.432	0.331	0.125	0.0395	14

根据红树莓籽油在 0~35 d 的贮藏中各个组分的含量，用于主成分分析。结合表 4、表 5 可知，提取出的 4 个主成分的累积方差贡献率为 93.30%>80%，即可解释原变量 93.30%的信息且基本反映了所有原变量的信息。在红树莓籽油加速贮藏过程中 PUFA、UFA、亚油酸、亚麻酸、α-生育酚、油酸、MUFA、β-谷甾醇、花生酸、过氧化值、DPPH·清除率、硬脂酸占红树莓籽油加速贮藏过程中综合指标中 88.26%的权重，是红树莓籽油加速贮藏稳定性的重要指标，其中的 PUFA 权重最高为 9.56%，其次为 UFA 9.43%，再次亚油酸 9.24%，权重越高则对籽油的贮藏稳定性影响越大。第一主成分的特征值为 9.83，贡献率为

影响越大。第一主成分的特征值为 9.83，贡献率为 65.54%，代表了全部信息的 65.4%，主要反映了棕榈酸、油酸、亚油酸、亚麻酸、花生酸、MUFA、UFA、PUFA、α-生育酚、β-谷甾醇、DPPH·清除率、$ABTS^{+}$·清除率正显著相关，过氧化值、硬脂酸负显著相关，对第一主成分贡献最大的为α-生育酚和β-谷甾醇，载荷量分别是 0.962 和 0.926；第二主成分的特征值为 1.631，贡献率为 10.87%，主要代表亚油酸和 $ABTS^{+}$·的含量；第三主成分特征值为 1.439，贡献率为 9.59%，主要代表棕榈酸的含量；第四主成分特征值为 1.095，贡献率为 7.30%，主要代表过氧化值的含量。

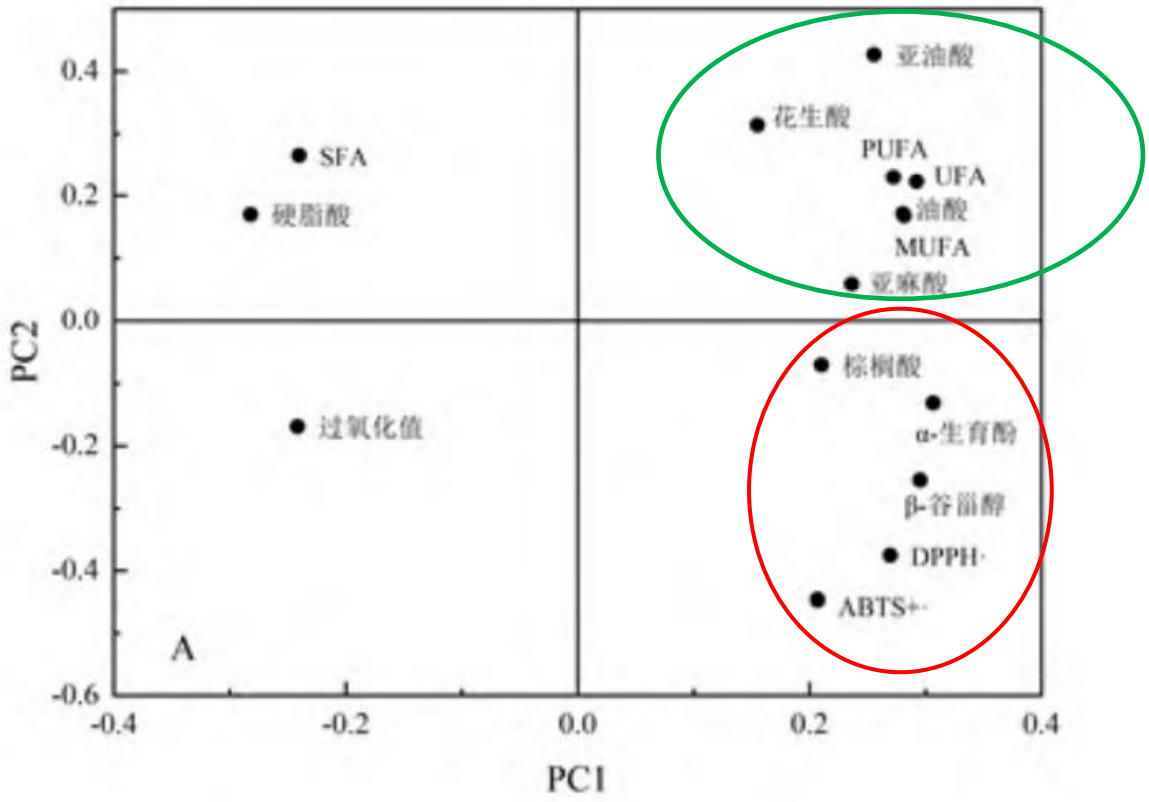
$$F_1=-0.282Z_{过氧化值}+0.246Z_{棕榈酸}-0.329Z_{硬脂酸}+0.328Z_{油酸}+0.299Z_{亚油酸}+0.276Z_{亚麻酸}+0.181Z_{花生酸}-0.280Z_{SFA}+0.329Z_{MUFA}+0.318Z_{PUFA}+0.341_{ZUFA}+0.345Z_{\beta\text{-谷甾醇}}+0.358Z_{\alpha\text{-生育酚}}+0.315Z_{DPPH\cdot}+0.242Z_{ABTS^{+}\cdot}$$

$$F_2=-0.252Z_{过氧化值}-0.104Z_{棕榈酸}+0.253Z_{硬脂酸}+0.255Z_{油酸}+0.634Z_{亚油酸}+0.087Z_{亚麻酸}+0.466Z_{花生酸}+0.394Z_{SFA}+0.249Z_{MUFA}+0.342Z_{PUFA}+0.332_{UFA}-0.379Z_{\beta\text{-谷甾醇}}-0.195_{\alpha\text{-生育}}-0.559Z_{DPPH\cdot}-0.666Z_{ABTS^{+}\cdot}$$

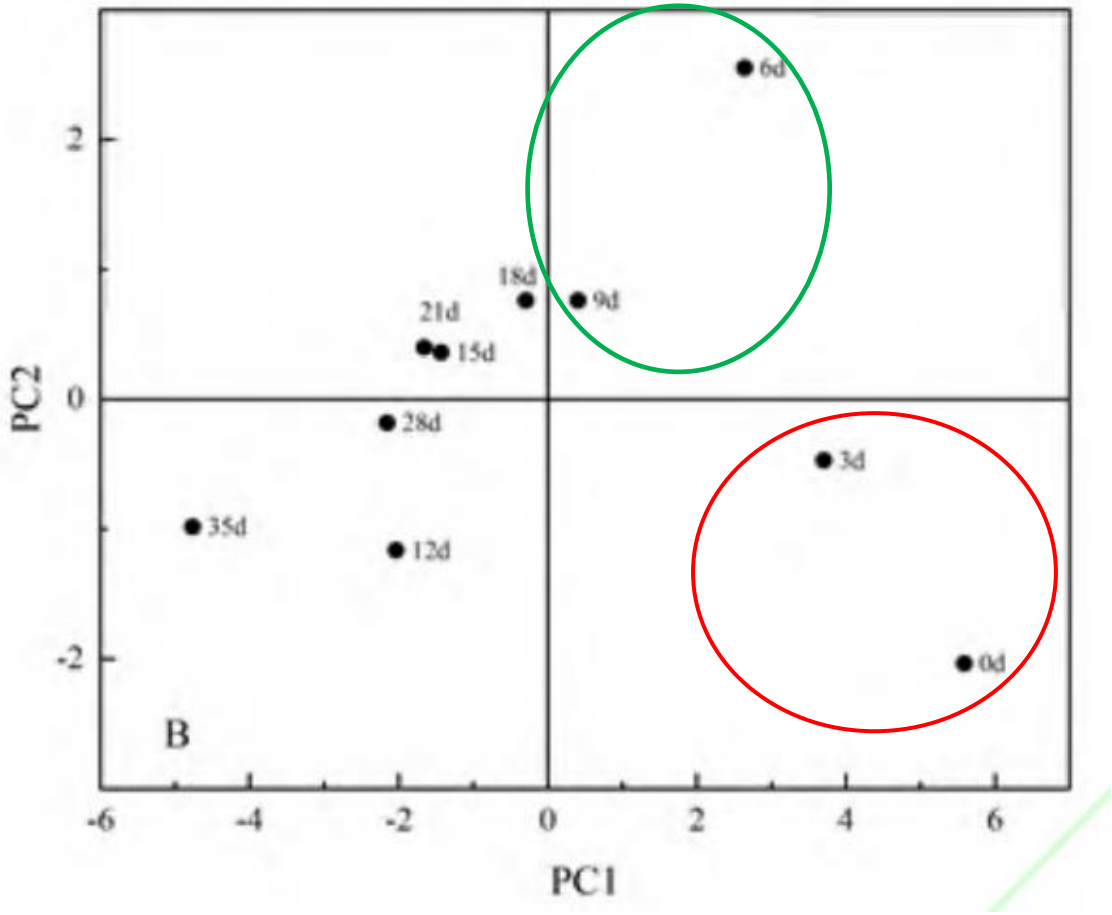
$$F_3=0.375Z_{过氧化值}-0.501Z_{棕榈酸}+0.211Z_{硬脂酸}-0.152Z_{油酸}-0.014Z_{亚油酸}+0.506Z_{亚麻酸}-0.202Z_{花生酸}+0.123Z_{SFA}-0.061Z_{MUFA}+0.332Z_{PUFA}+0.217Z_{UFA}+0.045Z_{\beta\text{-谷甾醇}}+0.017Z_{\alpha\text{-生育酚}}+0.170Z_{DPPH\cdot}+0.065Z_{ABTS^{+}\cdot}$$

$$F_4=0.117Z_{过氧化值}+0.131Z_{棕榈酸}+0.217Z_{硬脂酸}-0.242Z_{油酸}+0.116Z_{亚油酸}-0.002Z_{亚麻酸}+0.534Z_{花生酸}+0.157Z_{SFA}-0.236Z_{MUFA}+0.051Z_{PUFA}-0.045Z_{UFA}+0.041Z_{\beta\text{-谷甾醇}}+0.049Z_{\alpha\text{-生育酚}}+0.044Z_{DPPH\cdot}+0.331Z_{ABTS^{+}\cdot}$$

主成分1、2的载荷图


亚油酸
花生酸
PUFA
UFA
油酸
MUFA
亚麻酸
SFA
硬脂酸
棕榈酸
α-生育酚
β-谷甾醇
DPPH·
ABTS+·
过氧化值
A
0.4
0.2
0.0
-0.2
-0.4
-0.6
-0.4
-0.2
0.0
0.2
0.4
PC2
PC1

主成分1、2的得分图



红树莓籽油的贮藏第一主成分（PC1）和第二主成分（PC2）相关载荷图和主成分得分图如图 3 所示，PC1 主要对贮藏时间进行了划分，其中贮藏的 0 d 和 3 d 的红树莓籽油分布在 PCA 得分图（B）的第四象限，说明其与 PC1 成正相关，与 PC2 成负相关，棕榈酸、α-生育酚、β-谷甾醇、DPPH·清除率、$ABTS^{+}$·清除率与 PC1 呈正相分布，与 PC2 呈负相分布；在贮藏的 6 d 和 9 d 的红树莓籽油分布在 PCA 得分图（B）的第一象限，说明其与在 PC1 和 PC2 均为正相关，亚油酸、亚麻酸、花生酸、PUFA、UFA、油酸、MUFA 在 PC1 和 PC2 上呈正向分布，即这些组分在红树莓籽油贮藏

的 6 d 和 9 d 均与 PC1、PC2 呈正相关；贮藏的 12 d 和 35 d 的红树莓籽油分布在第二、三象限，与 PC1 成负相关，其中 15、18、21 d 与 PC2 呈正相关并与 SFA 和硬脂酸对应，12、28、35 d 与 PC2 呈负相关并与过氧化值对应，即在红树莓籽油贮藏的 0~9 d 油脂的成分变化较大，且以 0~3 d 内的 α-生育酚、β-谷甾醇、DPPH·清除率、$ABTS^{+}$·清除率变化较大，表现出

案例3—基于主成分分析的苹果品种鉴别

为了去除来自高频随机噪声、基线漂移、样本不均匀、光散射等影响，需要进行光谱预处理来消除噪声。采用求平均平滑法，选用平滑窗口大小为 9，此时能很好滤除各种因素产生的高频噪声，再进行 MSC 处理。由于系统误差样本光谱曲线在首端和末端有较大噪声如图 1 所示，所以只取 400～960 nm 波段的光谱用于分析。

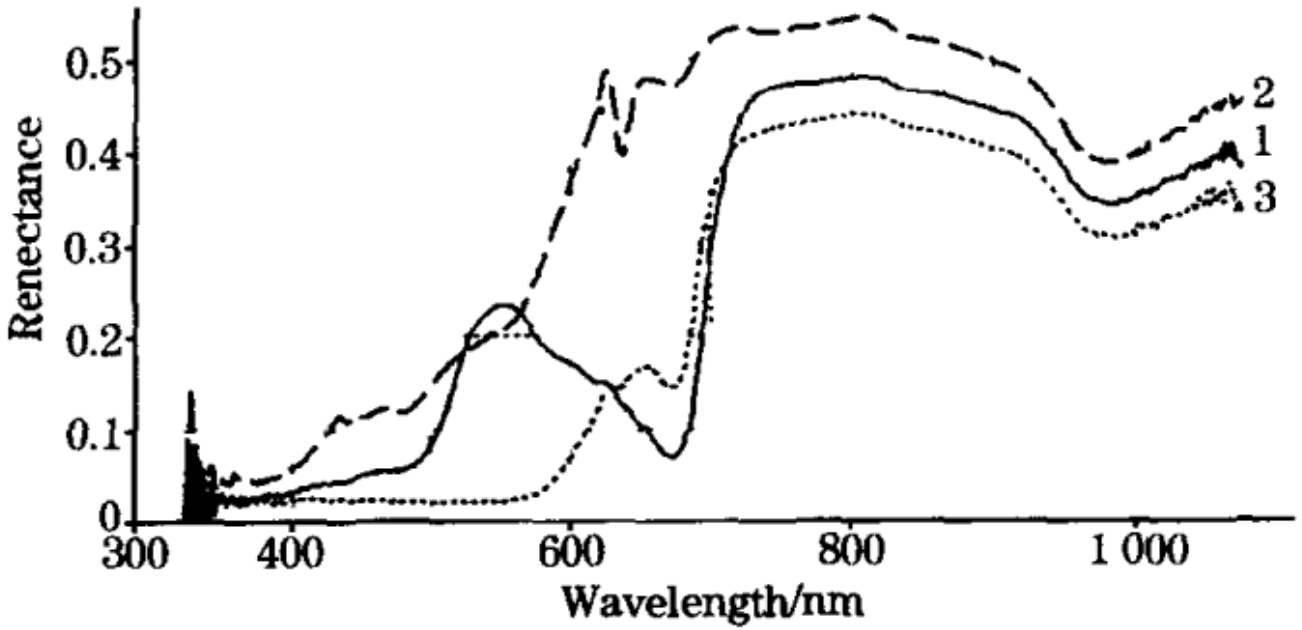


Fig. 1 Near infrared reflectance spectra of three different variety apples

1: Copefrut royal gala; 2: Fuji; 3: Red delicious

Table 1 PCs and reliabilities

主成分	PC1/%	PC2/%	PC3/%
累计可信度	68	98	99.398

由于前两个主成分的累计可信度已达98%，所以仅用前两个主成分就可以表示原始近红外光谱的主要信息[9]。

主成分得分图

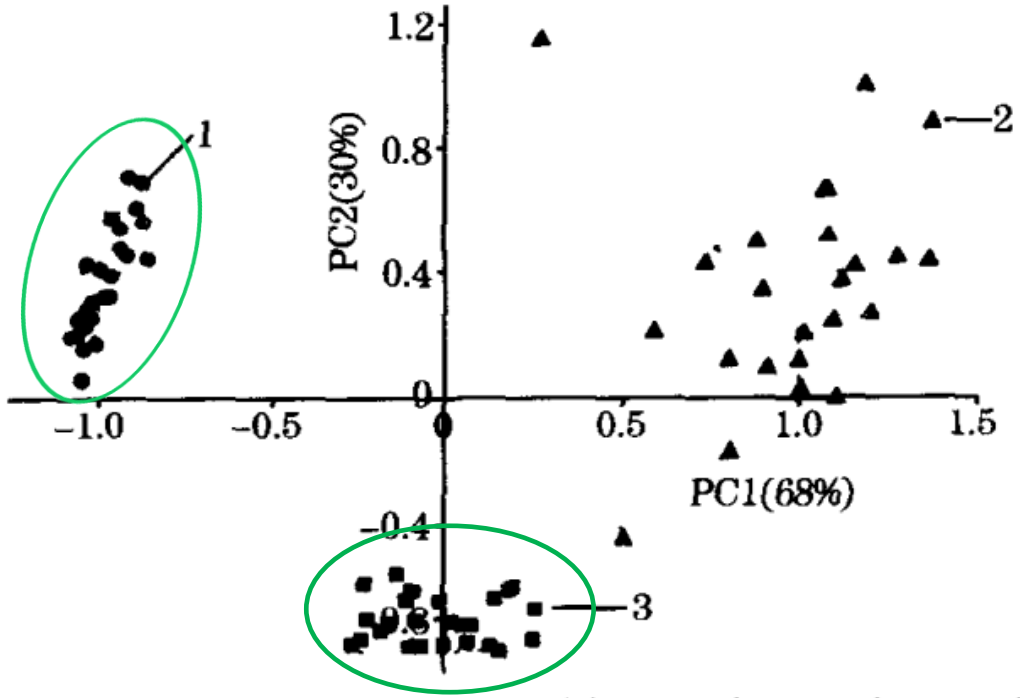
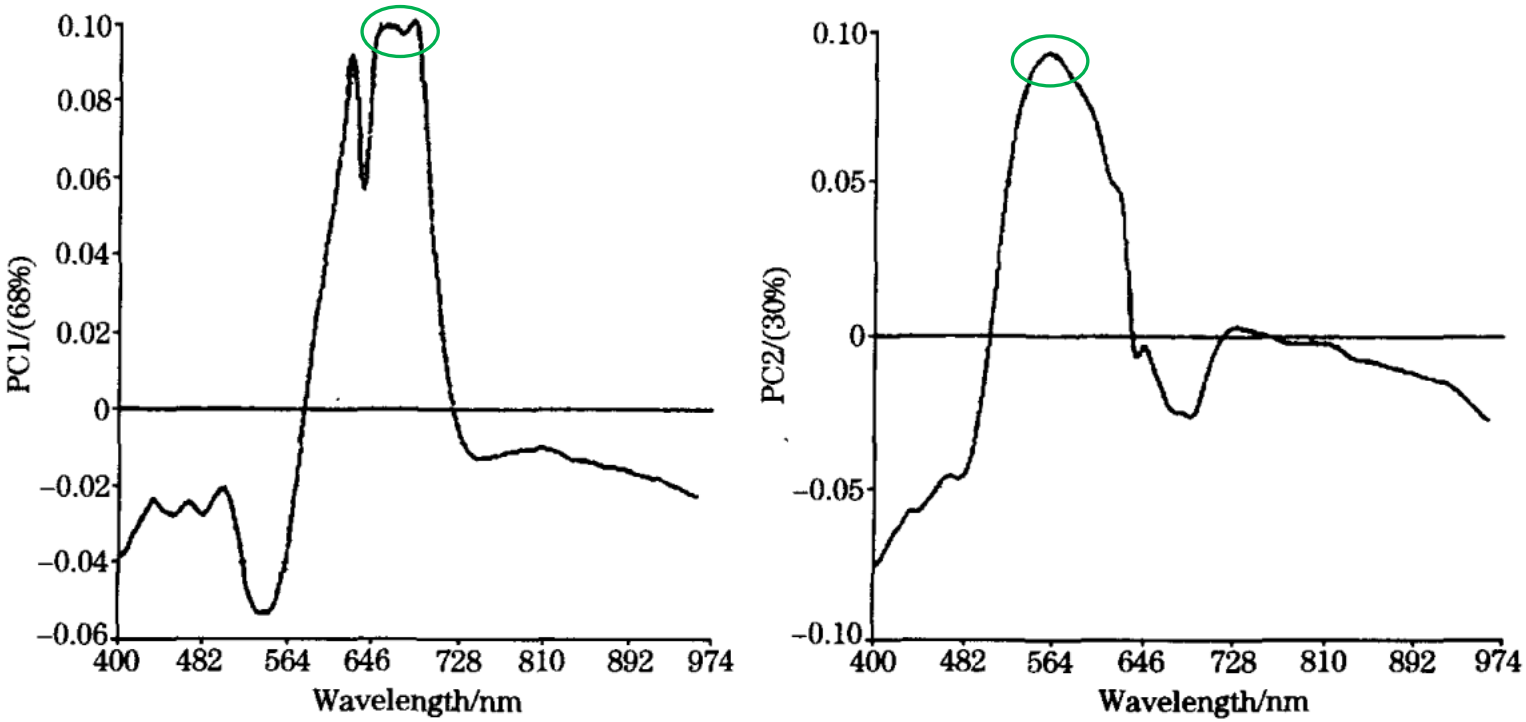


Fig. 2 PCA scores plots(PC1×PC2) for apple sample

1: Copefrut royal apple; 2: Fuji apple; 3: Red delicious apple

图 2 表示 75 个建模样本的主成分 1，2 得分图，图中横坐标表示每个样本的第一主成分得分值，纵坐标表示每个样本的第二主成分得分值。图 2 中水晶红富士(Fuji)，Red delicious，Copefrut royal gala 三个品种苹果明显分成三类，说明主成分 1，2 对三种苹果有较好的聚类作用。因此，本研究基于主成分 1、2 对于 75 个样本的得分图，对 75 个苹果样本进行聚类分析。从图 2 中可以看出，品种为 Red delicious 的 25 个样本聚合度较好而且均位于 x 轴的下方，其他 50 个样本大部分位于 x 轴的上方。品种为 Copefrut royal gala 的 25 个样本聚合度较好，紧密的分布在图 2 的第二象限，其他样本均处于第二象限之外。品种为水晶红富士(Fuji)的苹果样本聚合度不如另外两种，但是除了有两个样本位于第四象限其它全部分布在第一象限之内，而另两个品种均在第一象限之外。

主成分载荷图



(a) The loading plot of prin 1

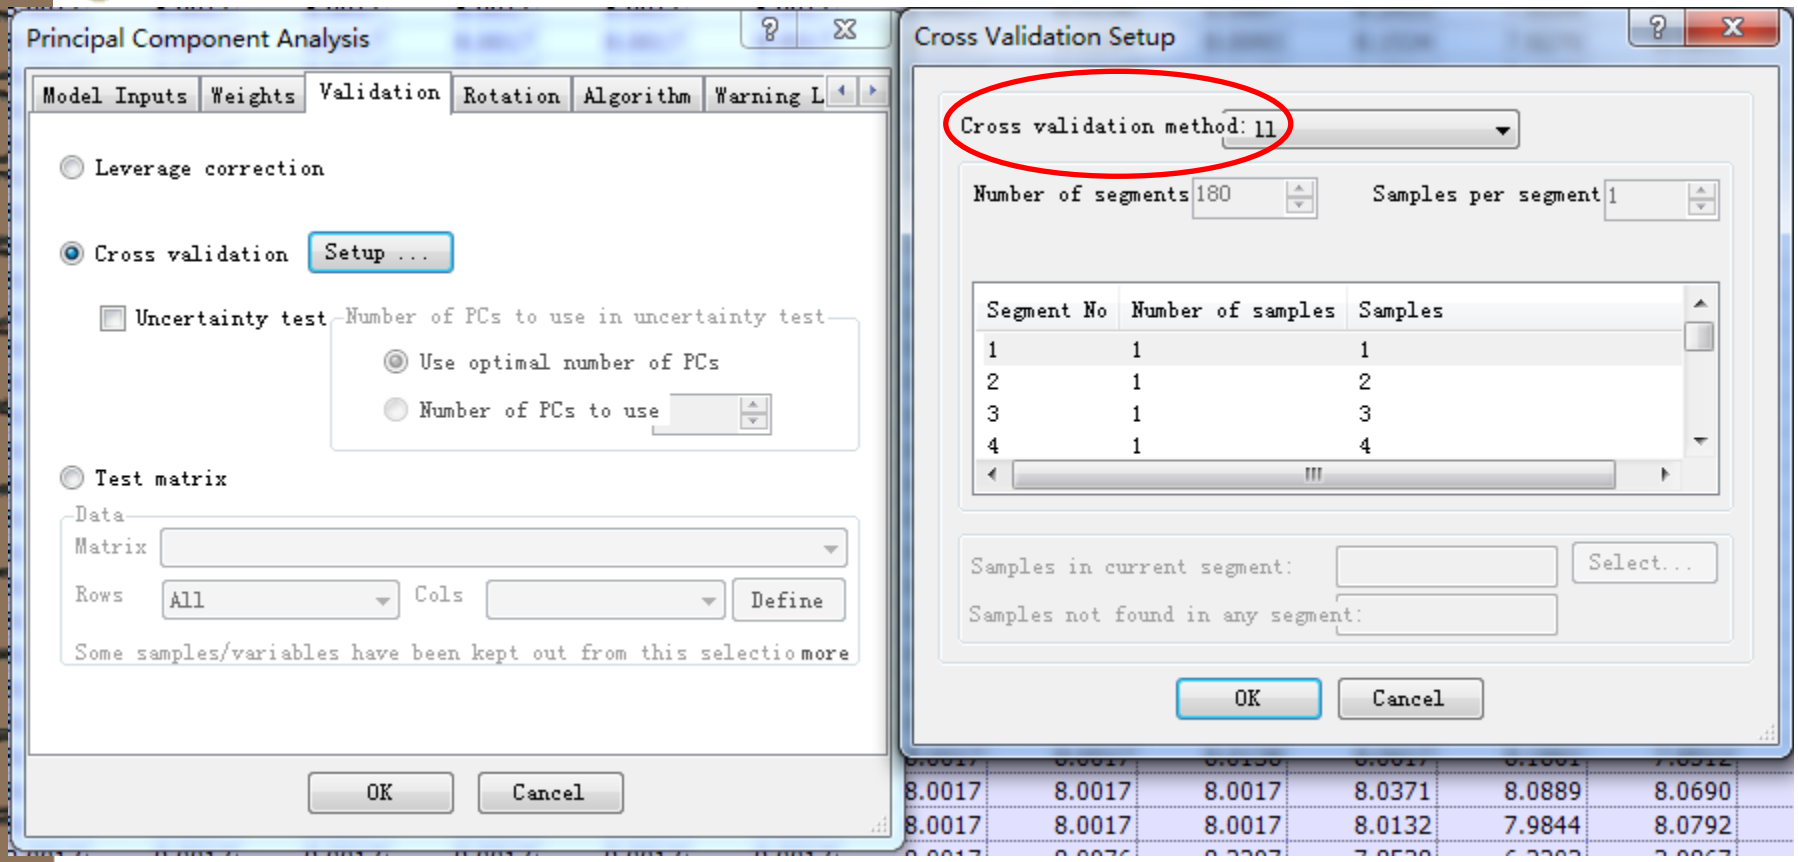
(b) The loading plot of prin 2

Fig. 3 The loading plot of prin1 and prin2 across the entire spectral region

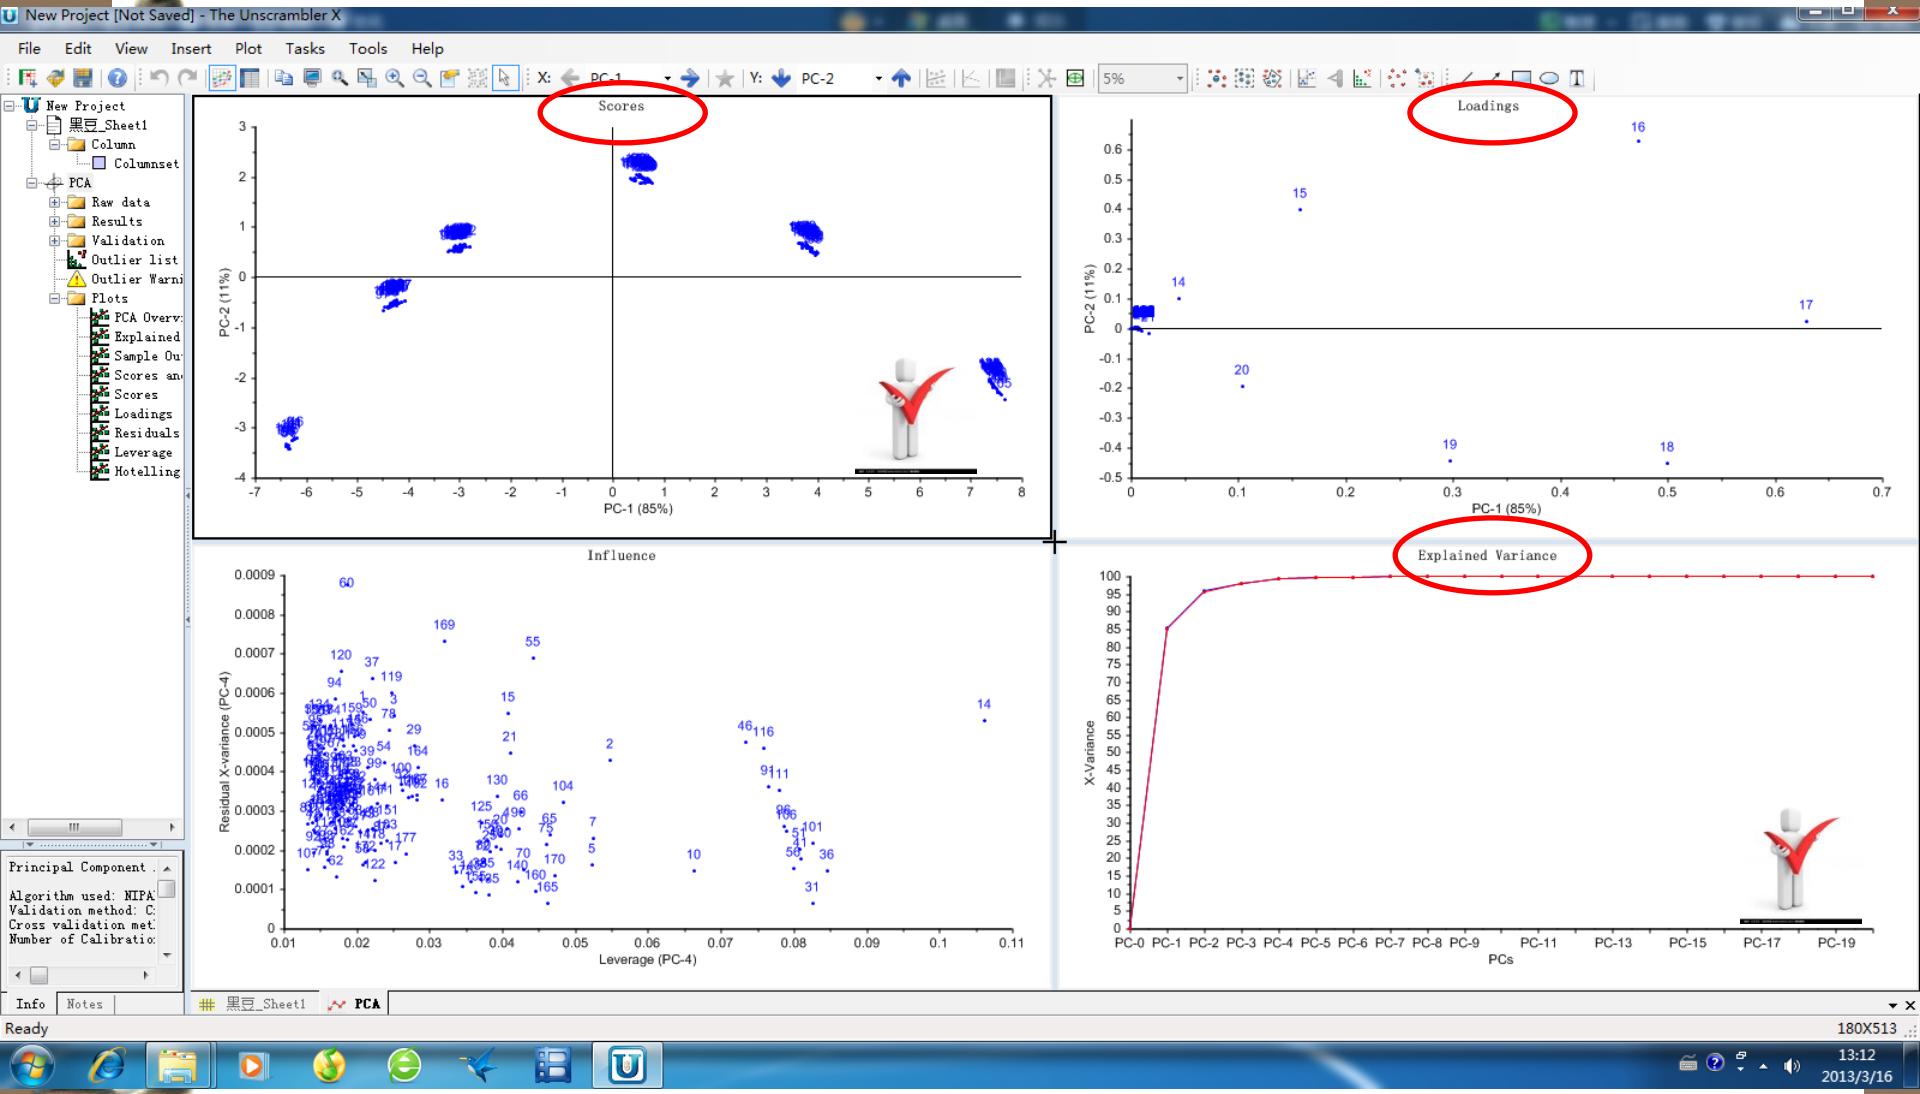
品种预测模型。图 3 表示主成分 1 和主成分 2 在整个波长范围的载荷图。从图 3 中可以看出主成分 1，2 与全波长变量的相关程度。图 3 中横坐标表示波长范围 400～960 nm，纵坐标表示各波长变量对于主成分的载荷值，即是各个波长变量与主成分的相关性大小。从图 3(a)可以看出主成分 1 与波长 650～690 nm 的相关性较大，即主成分 1 与波长 650～690 nm 范围的反射值的相关性较强；从图 3(b)可以看出主成分 2与波长 550～565 nm 范围的反射值的相关性较强。又从表 1可知主成分 1，2 的累积可信度已达到 98%，即主成

分 1，2 几乎能完全解释所有原变量，而且从图 2 可以看出主成分 1，2 对三类苹果有较好的聚类作用，所以与它们紧密相关的波长 550～565 nm 和 650～690 nm 范围是对苹果品种极为敏感的特征波长。所以从 400～960 nm 范围的 561 个采样

Unscrambler---PCA算法



Unscrambler ---PCA Overview



定性的聚类分析---scores 图

属于同一茶叶品种，前2个主成分的区分效果不佳!

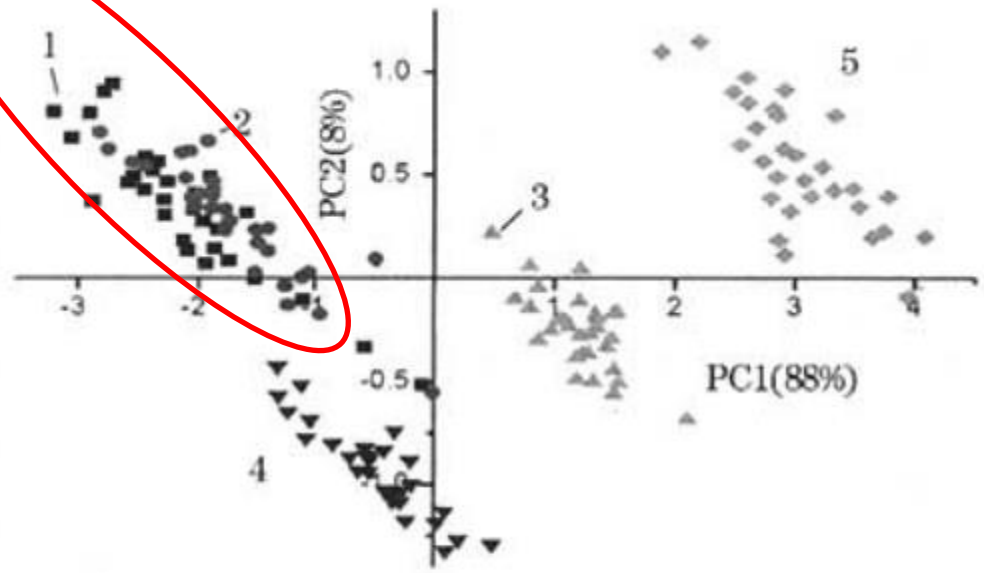


Fig PCA scores plots(PC1×PC2) for tea sample across the entire spectral region

1：西湖龙井；2:浙江龙井；3：羊岩勾青；4：雪水云绿；5：庐山云雾

✓5种茶叶的样本点分布在5个平行的条状块中。

✓当主成分1增大时，主成分2减小，即主成分1和2呈负相关。

PCA-载荷图

有助于提取特征波长!

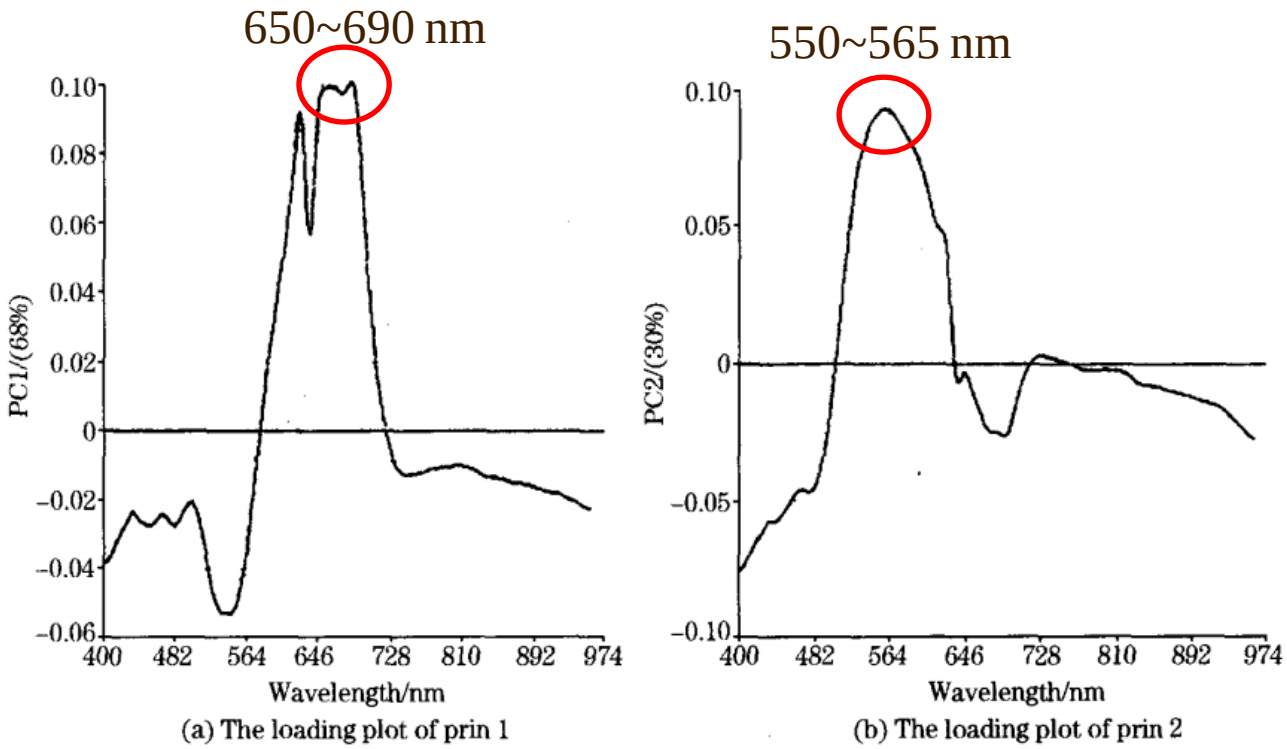


Fig. 3 The loading plot of prin1 and prin2 across the entire spectral region

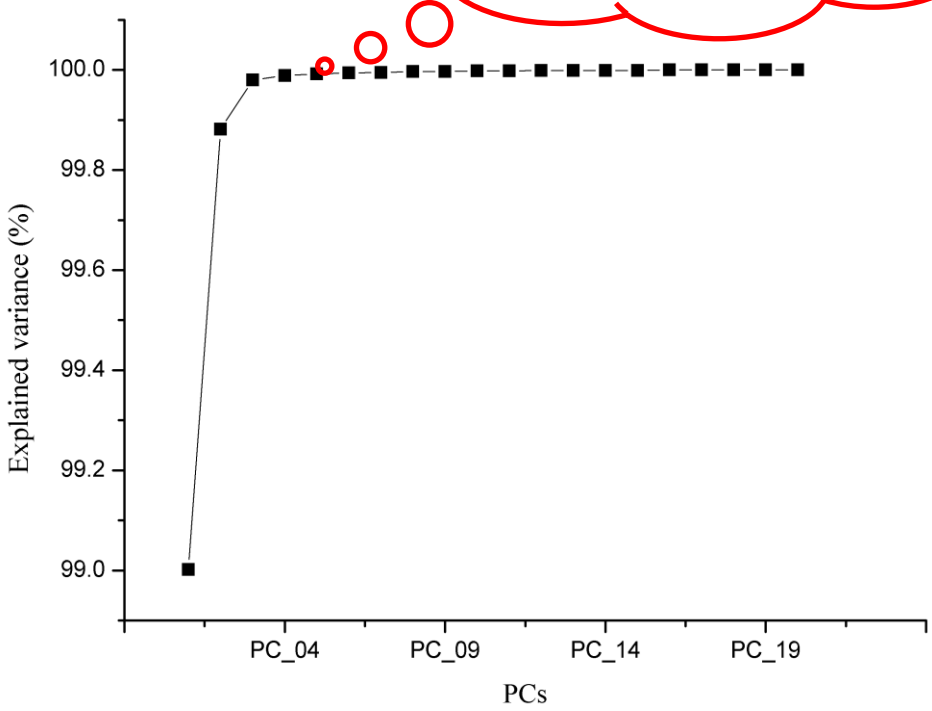
横坐标表示波长范围400～960nm，纵坐标表示各波长变量对于主成分的载荷值，即各个波长变量与主成分的相关性大小。

累计贡献率

- 贡献率表示所定义的主成分在整个数据分析中承担的主要意义占多大的比重。

- 当取前r个主成分来代替原来全部变量时，累计贡献率的大小反应了这种取代的可靠性，累计贡献率越大，可靠性越大；反之，则可靠性越小。

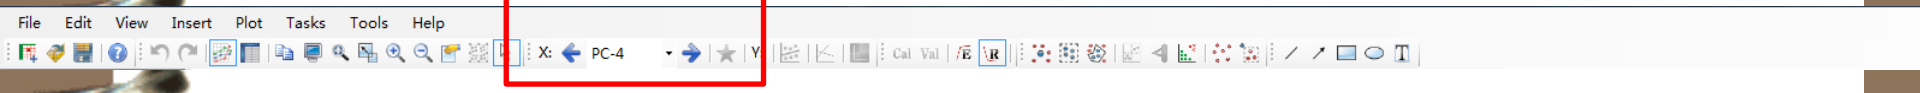
一般要求累计贡献率达到70%以上。



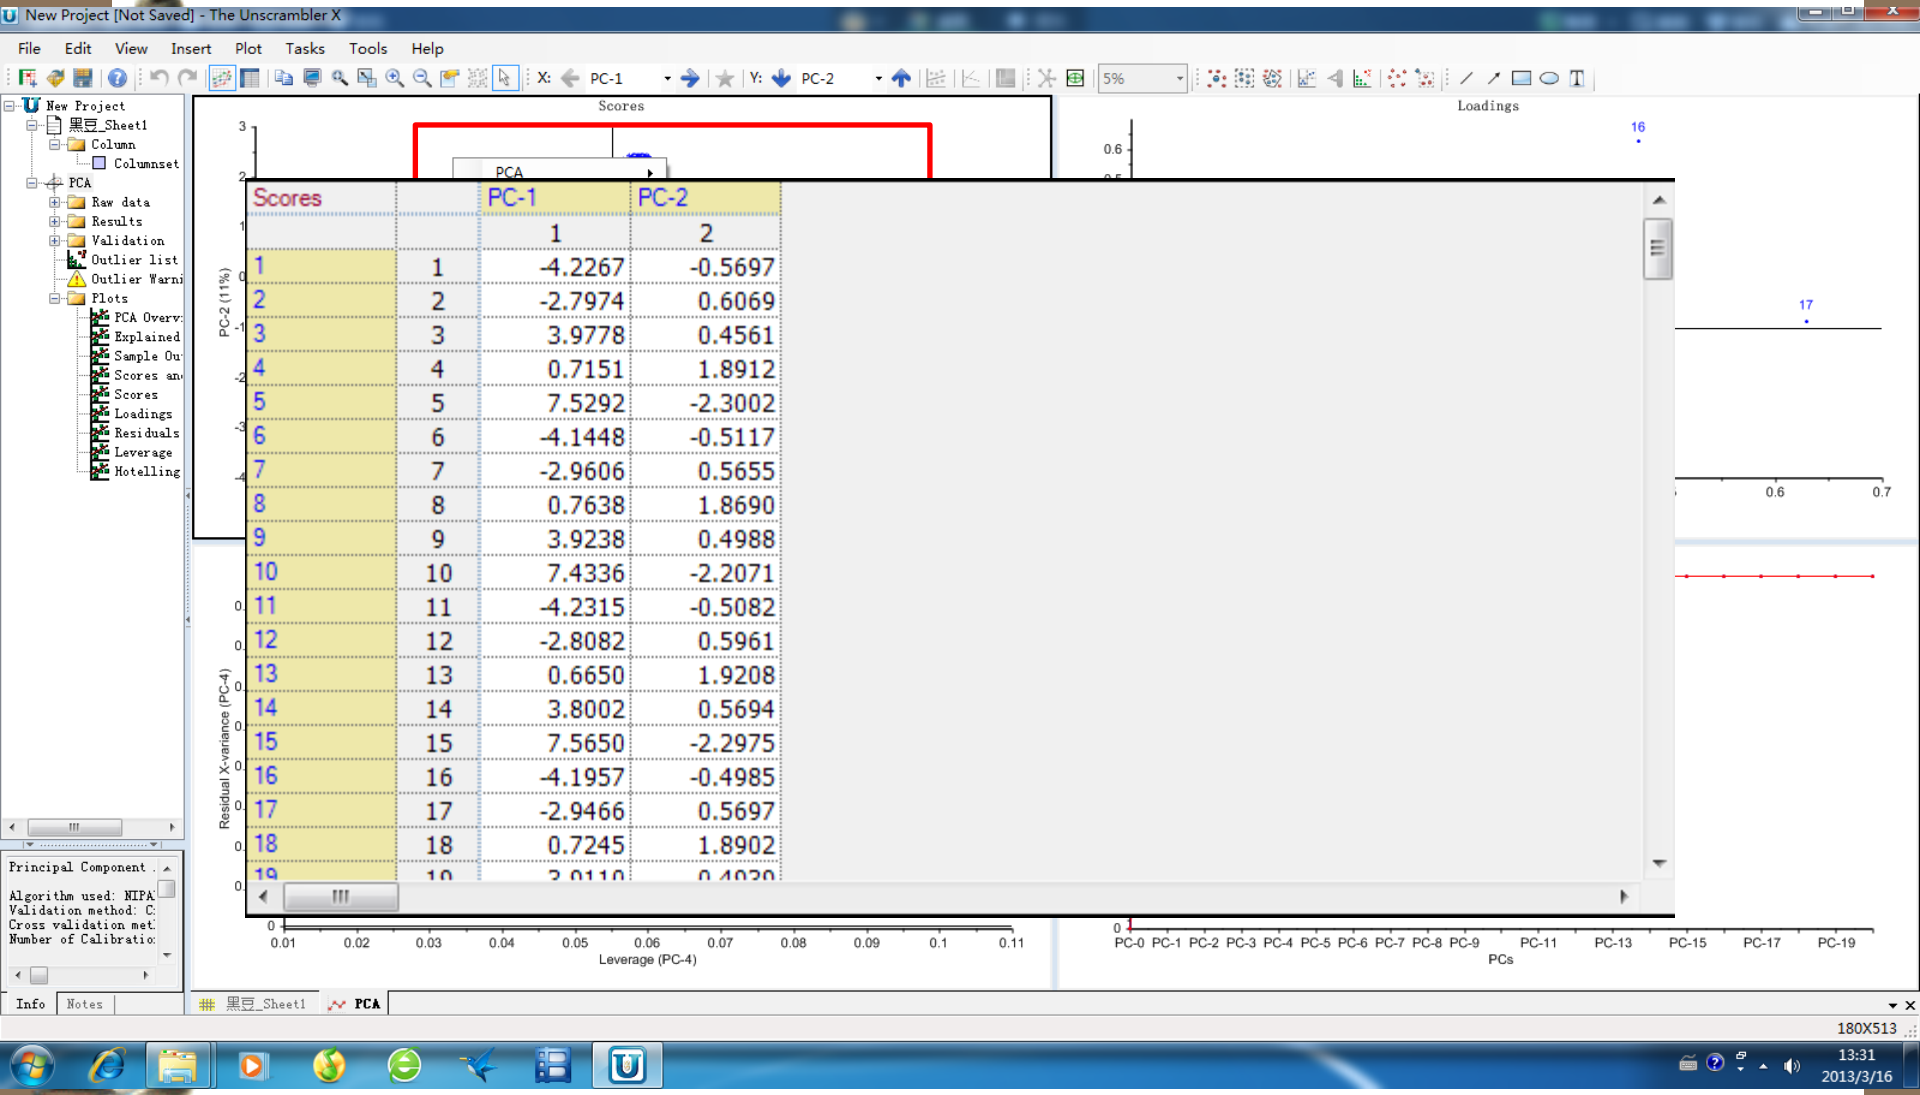
The first 4 PCs are sufficient to represent 99.9% of the original information from the image

Unscrambler -PCA

主成分数的切换



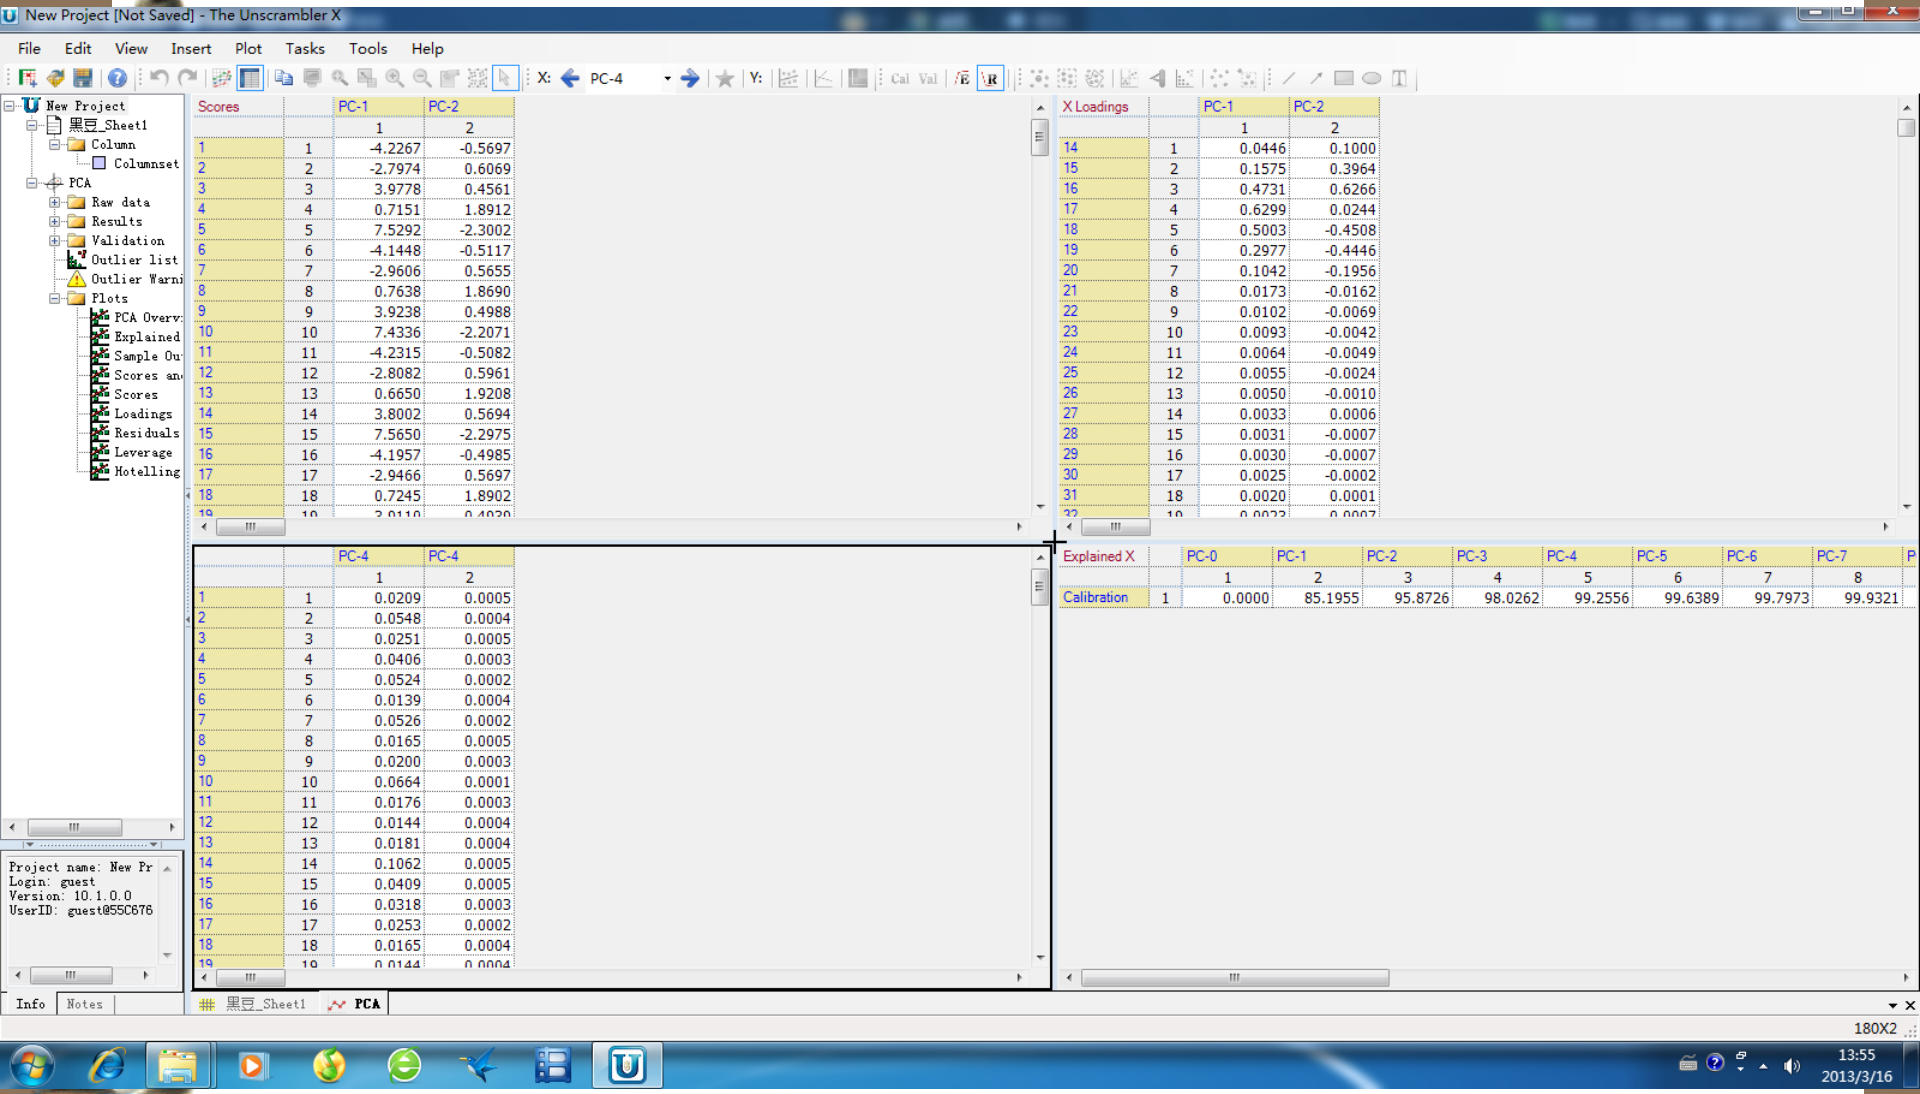
PCA-Scores



Scores		PC-1	PC-2
		1	2
1	1	-4.2267	-0.5697
2	2	-2.7974	0.6069
3	3	3.9778	0.4561
4	4	0.7151	1.8912
5	5	7.5292	-2.3002
6	6	-4.1448	-0.5117
7	7	-2.9606	0.5655
8	8	0.7638	1.8690
9	9	3.9238	0.4988
10	10	7.4336	-2.2071
11	11	-4.2315	-0.5082
12	12	-2.8082	0.5961
13	13	0.6650	1.9208
14	14	3.8002	0.5694
15	15	7.5650	-2.2975
16	16	-4.1957	-0.4985
17	17	-2.9466	0.5697
18	18	0.7245	1.8902
19	19	3.9110	0.4939

PCA Results

Graphical view-Numerical view



Scores

		PC-1	PC-2
		1	2
1	1	-4.2267	-0.5697
2	2	-2.7974	0.6069
3	3	3.9778	0.4561
4	4	0.7151	1.8912
5	5	7.5292	-2.3002
6	6	-4.1448	-0.5117
7	7	-2.9606	0.5655
8	8	0.7638	1.8690
9	9	3.9238	0.4988
10	10	7.4336	-2.2071
11	11	-4.2315	-0.5082
12	12	-2.8082	0.5961
13	13	0.6650	1.9208
14	14	3.8002	0.5694
15	15	7.5650	-2.2975
16	16	-4.1957	-0.4985
17	17	-2.9466	0.5697
18	18	0.7245	1.8902

X Loadings

		PC-1	PC-2
		1	2
14	1	0.0446	0.1000
15	2	0.1575	0.3964
16	3	0.4731	0.6266
17	4	0.6299	0.0244
18	5	0.5003	-0.4508
19	6	0.2977	-0.4446
20	7	0.1042	-0.1956
21	8	0.0173	-0.0162
22	9	0.0102	-0.0069
23	10	0.0093	-0.0042
24	11	0.0064	-0.0049
25	12	0.0055	-0.0024
26	13	0.0050	-0.0010
27	14	0.0033	0.0006
28	15	0.0031	-0.0007
29	16	0.0030	-0.0007
30	17	0.0025	-0.0002
31	18	0.0020	0.0001

		PC-4	PC-4
		1	2
1	1	0.0209	0.0005
2	2	0.0548	0.0004
3	3	0.0251	0.0005
4	4	0.0406	0.0003
5	5	0.0524	0.0002
6	6	0.0139	0.0004
7	7	0.0526	0.0002
8	8	0.0165	0.0005
9	9	0.0200	0.0003
10	10	0.0664	0.0001
11	11	0.0176	0.0003
12	12	0.0144	0.0004
13	13	0.0181	0.0004
14	14	0.1062	0.0005
15	15	0.0409	0.0005
16	16	0.0318	0.0003
17	17	0.0253	0.0002
18	18	0.0165	0.0004

Explained X

		PC-0	PC-1	PC-2	PC-3	PC-4	PC-5	PC-6	PC-7	P
		1	2	3	4	5	6	7	8	
Calibration	1	0.0000	85.1955	95.8726	98.0262	99.2556	99.6389	99.7973	99.9321	

PCA-Loadings

